BỘ GIÁO DỤC VÀ ĐÀO TẠO - TRƯỜNG ĐẠI HỌC CÔNG THƯƠNG TP.HCM (HUIT)
KHOA CÔNG NGHỆ THÔNG TIN - HỌC PHẦN: NHẬP MÔN DỮ LIỆU LỚN (BIG DATA)

BÁO CÁO TIẾN ĐỘ THỰC HIỆN ĐỒ ÁN MÔN HỌC

ĐỀ TÀI: XÂY DỰNG PIPELINE BIG DATA PHÂN TÍCH ĐA CHIỀU CÁC YẾU TỐ ẢNH HƯỞNG VÀ DỰ ĐOÁN NGUY CƠ NGHỈ VIỆC CỦA NHÂN VIÊN

(Hệ thống tích hợp: Apache Hadoop HDFS, PySpark, Spark SQL, Machine Learning MLlib, K-Means, Kafka, Airflow & NestJS Backend)

Sinh viên thực hiện:	Vũ Lê Anh Đức
Mã số sinh viên (MSSV):	2001230191
Lớp học phần:	Big Data - Tiết 10-12 (Khoa CNTT - HUIT)
Giảng viên hướng dẫn:	ThS. Ngô Dương Hà (hand@huit.edu.vn)
Không gian HDFS LMS:	/courses/2/projects/3/students/2001230191/

1. TỔNG QUAN ĐỀ TÀI & BÀI TOÁN BIG DATA

Đề tài tập trung giải quyết bài toán cốt lõi trong quản trị doanh nghiệp: Dự đoán nguy cơ nhân viên nghỉ việc (Employee Attrition) và bóc tách các nguyên nhân trọng yếu (chế độ OverTime, mức độ hài lòng, chênh lệch thu nhập). Dự án xây dựng một hệ sinh thái Big Data 6 tầng hoàn chỉnh theo đúng chuẩn kiến trúc hiện đại: Storage -> Ingestion -> Processing -> Query -> BI/ML -> Orchestration & Serving.

THÔNG SỐ VÀ ĐẶC ĐIỂM DỮ LIỆU:

• Bộ dữ liệu sử dụng: IBM HR Analytics (WA_Fn-UseC_-HR-Employee-Attrition.csv) gồm 1,470 bản ghi và 35 thuộc tính.
• Thách thức kỹ thuật: Mất cân bằng dữ liệu lớp (Class Imbalance: tỷ lệ 1 : 5.2 tương ứng 16.12% nghỉ việc vs 83.88% ở lại).
• Giải pháp đặc thù: Không dùng Accuracy làm tiêu chí duy nhất; áp dụng Balanced Class Weighting và đánh giá bằng ROC-AUC (~0.81) & Recall (68.09%). Đồng thời phân cụm K-Means 4 nhóm nhân sự để định biên quản trị.

2. ĐỐI CHIẾU BÀI GIẢNG CHƯƠNG 4: XỬ LÝ DỮ LIỆU VỚI APACHE SPARK

Bám sát nội dung bài giảng Chương 4 của ThS. Ngô Dương Hà (Khoa CNTT - HUIT), đồ án đã giải quyết trực tiếp các bài toán lý thuyết và khắc phục triệt để các hạn chế cốt lõi của mô hình Hadoop MapReduce truyền thống:

SỰ KẾT NỐI VỚI NỘI DUNG CHƯƠNG 4:

1. Khắc phục hạn chế của MapReduce (Slide 20 bài giảng):
- Bài giảng chỉ ra MapReduce chạy chậm do ghi/đọc đĩa liên tục (frequent disk I/O) và không tối ưu cho Machine Learning/Streaming.
- Đồ án đã thay thế bằng Apache Spark In-Memory Computing (Slide 21), lưu trữ và xử lý trực tiếp trên RAM, giúp tốc độ truy vấn tăng gấp 10-100 lần.

2. Hiện thực hóa trọn vẹn Hệ sinh thái Spark (Slide 22 bài giảng):
- Spark Core / DataFrame: Đọc phân tán và tự động suy luận Schema (step3_spark_read.py).
- Spark SQL: Thực thi 6 truy vấn phân tích đa chiều chuyên sâu (step5_spark_sql.py).
- Spark MLlib: Huấn luyện Random Forest và phân cụm K-Means K=4 nhóm (step6_ml_predict.py).
- Spark Streaming & Kafka: Thu thập và xử lý dòng sự kiện thời gian thực (step8_kafka_simulation.py).

3. KẾT QUẢ VÀ TIẾN ĐỘ LÀM VIỆC TUẦN NÀY (ĐIỂM NHẤN HOÀN THIỆN)

Trong tuần này, sinh viên đã hoàn thành xuất sắc 8 hạng mục công việc trọng điểm theo đúng yêu cầu đề bài của nhóm, nâng cấp toàn bộ hệ thống từ mức kiểm thử cơ bản lên cấp độ hoàn thiện hệ sinh thái Big Data toàn trình:

Hạng mục công việc tuần này	Kỹ thuật & Công nghệ triển khai	Kết quả thực nghiệm đạt được
1. Phân Vùng Parquet, Gộp File & Đối Chiếu HDFS	Phân vùng Parquet theo Department (3 partitions). Gộp Parquet tối ưu 1 Block (step4b_parquet_compaction.py). Đối chiếu số lượng bản ghi HDFS.	1,470 bản ghi khớp 100%, Null=0 (Zero loss). Tiết kiệm 59.9% dung lượng đĩa, quét nhanh hơn 4.5 lần. Báo cáo: hdfs_reconciliation_audit.json.
2. Truy vấn Spark SQL Đa Chiều (6 Queries)	Tạo TempView In-Memory SQL. Thực thi 6 truy vấn đa chiều phân tích: OverTime, Phòng ban, Chức vụ, WorkLifeBalance, Thâm niên, Môi trường.	Xuất spark_sql_analytics.json. Khối Sales tỷ lệ nghỉ 20.6%, nhóm OverTime nghỉ 30.5% (gấp 3 lần không OverTime: 10.4%).
3. Tinh Chỉnh Mô Hình & So Sánh Các Lần Chạy	So sánh 3 lần huấn luyện: Run 1 (Baseline Logistic Regression), Run 2 (Default RF), Run 3 (Tuned Balanced RF 100 cây, max_depth=12).	Đạt Accuracy 83.33% - 83.67%, ROC-AUC 0.8095, Recall 68.09%. Xuất bảng đối chiếu: model_experiments_comparison.json.
4. Phân Tích Các Trường Hợp Dự Đoán Sai	Bóc tách nguyên nhân Error Analysis: False Positives (8 ca: đoán nghỉ nhưng ở lại) & False Negatives (41 ca: đoán ở lại nhưng nghỉ).	Giải thích: FP do bù đắp bởi StockOption/Quản lý; FN do chậm thăng tiến nhiều năm (Promotion_Lag cao). Báo cáo: misclassified_cases_analysis.json.
5. Lưu Trữ Mô Hình Đã Huấn Luyện (Model Persistence)	Lưu trữ mô hình Random Forest và bộ Scaler vật lý vào tệp phục vụ suy luận tức thì trong môi trường Production.	Đã xuất: data/output/model_random_forest.pkl (348 KB) và data/output/model_scaler.pkl.
6. Phân Cụm K-Means & 6/6 Test Suites	Thuật toán K-Means phân cụm trên các chiều Age, Income, Tenure, WorkLifeBalance thành 4 nhóm nhân sự; chạy kiểm thử tự động.	4 nhóm rõ rệt (Cốt cán $15.5k, Nguy cơ cao $3.5k, Trẻ, Ổn định). Vượt qua 6/6 Test Suites Passed chuẩn Big Data.
7. Kafka Streaming & Kiểm Thử Luồng E2E	Producer phát event IoT chấm công/log vào Topic hr-employee-events; Consumer AI chấm điểm rủi ro 3 cấp độ	Luồng khép kín E2E: Input HDFS (12ms) -> Kafka (45ms) -> Spark (85ms) -> AI (6ms) -> Output (28ms). Tất cả 5 chặng

	(Xanh/Vàng/Đỏ). Kiểm thử E2E 5 chặng.	PASSED.
8. Điều Phối Airflow DAG & Full-Stack Serving	Định nghĩa DAG 9 tasks có dependencies, lập lịch @daily. Xây dựng NestJS REST API (port 3000) và Web Dashboard 6 Tabs.	Hệ thống trực quan hóa 6 Tabs tương tác, tích hợp Chart.js, Live Streaming Ticker và AI Risk Simulator.

4. SỐ LIỆU THỰC NGHIỆM VÀ BENCHMARK HỆ THỐNG

Bảng số liệu đối sánh thực nghiệm lưu trữ và tính toán đã đo lường trên cụm hệ thống:

Tiêu chí đối sánh	Hadoop CSV Thô	Snappy Parquet (Spark)	Hiệu quả cải thiện
Dung lượng đĩa	222.63 KB	89.06 KB	Tiết kiệm 59.9% dung lượng lưu trữ HDFS
Tổ chức dữ liệu	Dạng dòng (Row-oriented)	Dạng cột (Columnar)	Tối ưu hóa nén và truy vấn theo thuộc tính
Tốc độ quét Spark	Full scan toàn bộ tệp	Predicate Pushdown & Projection	Nhanh hơn 4.5 lần so với đọc CSV
Thời gian truy vấn SQL	~1.5 - 2.0 giây	0.0 - 0.2 ms / truy vấn	Tăng tốc độ In-Memory gấp 10 lần

5. HƯỚNG DẪN KIỂM TRA VÀ NGHIỆM THU (DÀNH CHO GIẢNG VIÊN)

Cách 1: Trải nghiệm Web Client Dashboard tương tác (Khuyến nghị)

1. Khởi động Web Server tại thư mục D:\Doan_BigData (hoặc chạy run_web.bat tại thư mục gốc):

```
$ python 1_HeThong_DuAn\app.py   (hoặc click đúp run_web.bat)
```

2. Truy cập trình duyệt tại địa chỉ: http://localhost:5000

3. Khám phá 6 Tab chức năng trực quan:

- Tab 1: Pipeline 9 Bước & Terminal thực hành interactive.
- Tab 2: Spark SQL với 6 biểu đồ Chart.js phân tích đa chiều chuyên sâu.
- Tab 3: Phân cụm K-Means 4 nhóm nhân sự & Top Feature Importances.
- Tab 4: Kafka Live Streaming với Live Ticker và bảng cảnh báo 3 cấp độ.
- Tab 5: Bộ mô phỏng AI Risk Simulator tính xác suất nghỉ việc và xuất khuyến nghị HR.
- Tab 6: Sơ đồ chuỗi điều phối Apache Airflow DAG và số liệu Benchmark.

Cách 2: Khởi động NestJS REST API Backend

Dự án NestJS TypeScript độc lập được đặt tại D:\Doan_BigData\1_HeThong_DuAn\backend-nestjs:

```
$ cd 1_HeThong_DuAn\backend-nestjs
$ npm install
$ npm run start:dev
```

Cung cấp đầy đủ REST API tại http://localhost:3000 phục vụ cho giao diện Web Client.

TP. Hồ Chí Minh, ngày 15 tháng 10 năm 2026

Sinh viên thực hiện báo cáo

Vũ Lê Anh Đức

(MSSV: 2001230191)